[MAC0211] Laboratório de Programação I
Aula 20
AWK
Geradores de Analisadores Léxicos – Flex

Alair Pereira do Lago

DCC–IME–USP

19 de maio de 2015

Na aula passada...

- Expressões regulares
- Awk (Parte 1)

[Aula passada] Awk

- O *Awk* é uma ferramenta para tratamento de textos baseada em expressões regulares
- Com ela, podemos fazer operações tais como:
  - Processamento de arquivos texto e criação de relatórios a partir dos resultados
  - Tradução de arquivos de um formato para outro
  - Criação de pequenos bancos de dados
  - Realização de operações matemáticas em arquivos de dados numéricos
- O *Awk* pode ser usado para realizar tarefas simples de processamento de texto via linha de comando, ou como uma linguagem de programação para a criação de scripts para processamentos mais complexos
- *Awk* vem do nome dos seus criadores: Aho, Weinberger & Kernighan

[Aula passada] Estrutura de um script Awk

- Formato mais simples:

```
awk '<padrão de busca> <ações do programa>' arq_entrada
```

- Formato mais geral:

```
awk [-F<sc>] 'prog' | -f <arq_prog> [<vars>] [-|<arq_entrada>]
```

sc	caracter separador de campo
prog	programa Awk de linha de comando
arq_prog	arquivo contendo um programa Awk
vars	inicialização de variáveis
-	lê da entrada padrão
arq_entrada	arquivo texto de entrada

onde arq_prog é um script que possui a seguinte estrutura

```
BEGIN                {<inicializações>}
<padrão de busca> {<ações do programa>}
<padrão de busca> {<ações do programa>}
...
END                  {<ações finais>}
```

[Aula passada] Awk – entradas

- O programa `awk` lê um script e o aplica na sua entrada
- O script pode ser passado como o primeiro parâmetro do programa (entre ‘ ’) ou então através da opção `-f nome_do_script`
- A entrada é quebrada em registros (normalmente, linhas)
- Os registros são quebrados em campos (normalmente, nos espaços em branco) que podem ser referenciados por meio das variáveis posicionais $1, $2, ..., $n
- $0 se refere ao registro inteiro
- `NR` é uma variável “embutida” que contém o número de registros já processados
- `NF` é a variável que contém o número de campos do registro atual
- `length` é a variável que contém o número de caracteres da linha atual
- Para definir um outro separador de campos, basta usar a opção `-F` no `awk` para determinar o separador.

[Aula passada] Expressões regulares do Awk

Semelhantes às do UNIX:

^	casa com o começo da string (p.ex., começo da linha)
$	casa com o fim da string (p.ex., fim da linha)
\	é o metacaracter de *escape*, que pode ser usado para remover o significado especial de um metacaracter
.	casa com qualquer caractere, inclusive o newline
[xyz]	casa com 1 caractere do conjunto xyz
[^xyz]	casa com 1 caractere qualquer que não esteja no conjunto xyz
|	para indicar alternativas (ou)
*	casa com a expressão anterior repetida 0 ou mais vezes
+	casa com a expressão anterior repetida 1 ou mais vezes
BEGIN	casa com o início do arquivo
END	casa com o final do arquivo

[Aula passada] Awk – exemplos simples

- Move todos os arquivos cujo nome inicia com “junk” para o diretório “lixo”, renomeando-os com uma extensão “’.lix’
  ls junk* | awk ‘{print “mv “$0” ../lixo/“$0”.lix”}’ | bash

- Calcula a soma e a média dos números armazenado em um arquivo (um número por linha)

```
BEGIN { s = 0 }
      { s += $1 }
END   { print "Soma: ", s, "Media: ", s/NR  }
```

- Calcula o tamanho médio das linhas de um arquivo

```
    { s += length }
END { print "Tamanho medio das linhas: ", s/NR }
```

[Aula passada] Outras características importantes do Awk

- As variáveis não são declaradas. Elas passam a existir na primeira vez em que são usadas
- Não existe tipo de variável; uma mesma variável pode conter num dado momento uma string e, num outro, um número
- Não é preciso inicializar variáveis; o valor inicial é sempre string vazia (o que é convertido em 0 numa operação aritmética)
- É possível a utilização de vetores. Os índices de vetores podem ser tanto números quanto strings (ver o exemplo anterior)

[Aula passada] Awk – exemplos envolvendo vetores

- Contador de ocorrências de palavras

```
    {
        for (i = 1; i <= NF; i++)
            freq[$i]++
    }
END {
        for (palavra in freq)
            printf "%s\t%d\n", palavra, freq[palavra]
    }
```

- Ordena um arquivo considerando como chave os valores numéricos armazenados em seu primeiro campo

```
    {
      if ($1 > max)
        max = $1
      vet[$1] = $0
    }
END {
      for (x = 1; x <= max; x++)
        if (x in vet)
          print vet[x]
    }
```

Awk – exemplos envolvendo busca de padrões

- Imprime todas as linhas que começam com uma vogal
  `awk '/^[AEIOUaeiou]/'`
- Imprime as linhas cuja segunda palavra é maior (numérica ou lexicograficamente) do que a primeira. A comparação será numérica se ambas palavras tiverem representação numérica
  `awk '$2 > $1'`
- Resultados de jogos onde o primeiro time venceu (o nome do time não pode ter espaços)
  `awk '/^[a-zA-Z]+ +[0-9]+ +x +[0-9]+ +[a-zA-Z]+/ && $2>$4'`
- Linhas começando com dígito ou com o 2º campo maior do que o 3º
  `awk '/^[0-9]/ || $2 > $3'`

Awk – exemplos envolvendo busca de padrões

- O operador $\sim$ é chamado de *match* e diz se uma expressão casa com um determinado padrão especificado através de uma expressão regular
- Os operadores $\sim$ e !$\sim$ podem ser usados como nos exemplos abaixo ou dentro de comandos if, while e for

Exemplos:

- linhas cujo primeiro campo casa com a expressão regular Janeiro.
  `awk '$1 ~ /Janeiro/'`
- Linhas cujo primeiro campo não casa a expressão regular Janeiro.
  `awk '$1 !~ /Janeiro/'`

Awk – outro exemplo

- Soma dos tamanhos dos arquivos cujo mês da última alteração é Maio:

```
ls -lg | awk '$6 == "Mai" { sum += $5 }
                    END { print sum }'
```

Obs.: A saída do comando `ls -lg` é algo como:

```
-rw-r--r--  1 arnold   user   1933 Nov  7 13:05 Makefile
-rw-r--r--  1 arnold   user  10809 Nov  7 13:03 gawk.h
-rw-r--r--  1 arnold   user    983 Apr 13 12:14 gawk.tab.h
-rw-r--r--  1 arnold   user  31869 Jun 15 12:20 gawk.y
-rw-r--r--  1 arnold   user  22414 Nov  7 13:03 gawk1.c
-rw-r--r--  1 arnold   user  37455 Nov  7 13:03 gawk2.c
-rw-r--r--  1 arnold   user  27511 Dec  9 13:07 gawk3.c
-rw-r--r--  1 arnold   user   7989 Nov  7 13:03 gawk4.c
```

Awk – um exemplo mais completo [1]

- Entrada: arquivo `coins.txt`, contendo a descrição de uma coleção de moedas
- Formato do arquivo de entrada: 5 colunas
  metal | peso | ano de cunhagem | país de origem | nome
- Exemplo:

```
gold      1     1986  USA                American Eagle
gold      1     1908  Austria-Hungary    Franz Josef 100 Korona
silver   10     1981  USA                ingot
gold      1     1984  Switzerland        ingot
gold      0.5   1981  RSA                Krugerrand
gold      0.1   1986  PRC                Panda
silver    1     1986  USA                Liberty dollar
gold      0.25  1986  USA                Liberty 5-dollar piece
silver    1     1987  USA                Constitution dollar
gold      0.25  1987  USA                Constitution 5-dollar piece
gold      1     1988  Canada             Maple Leaf
```

- Saída desejada: dados sumarizados da coleção de moedas

[1] Extraído de: *An Awk Primer* – `http://www.vectorsite.net/tsawk.html`

Awk – um exemplo mais completo

- Lista todas as moedas de ouro:

```
awk '/gold/' coins.txt
awk '/gold/ {print}' coins.txt
awk '/gold/ {print $0}' coins.txt
```

- Lista o nome de todas as moedas de prata:

```
awk '/silver/ {print $5,$6,$7,$8}' coins.txt
```

Note que algumas moedas possuem nomes compostos (com até 4 palavras); por essa razão, o comando acima imprime os valores dos campos de 5 a 8. Se uma dada linha não possui todos esses campos, o valor da variável correspondente ao campo "faltante" é string vazia

- Considerando que o valor do ouro por unidade de peso é $425, calcula o valor total das moedas de ouro:

```
awk '/gold/ {weight += $2} END {print "value =
$"425*weight}' coins.txt
```

Awk – um exemplo mais completo

```
# This is an awk program that summarizes a coin collection.
#
/gold/    { num_gold++; wt_gold += $2 }      # Get weight of gold.
/silver/  { num_silver++; wt_silver += $2 }  # Get weight of silver.
END { val_gold = 485 * wt_gold;              # Compute value of gold.
      val_silver = 16 * wt_silver;           # Compute value of silver.
      total = val_gold + val_silver;
      print "Summary data for coin collection:";  # Print results.
      printf ("\n");
      printf ("   Gold pieces:                  %2d\n", num_gold);
      printf ("   Weight of gold pieces:        %5.2f\n", wt_gold);
      printf ("   Value of gold pieces:       %7.2f\n",val_gold);
      printf ("\n");
      printf ("   Silver pieces:                %2d\n", num_silver);
      printf ("   Weight of silver pieces:      %5.2f\n", wt_silver);
      printf ("   Value of silver pieces:     %7.2f\n",val_silver);
      printf ("\n");
      printf ("   Total number of pieces:       %2d\n", NR);
      printf ("   Value of collection:        %7.2f\n", total); }
```

Awk – outras funcionalidades

- /(<string1>)|(<string2>)/ – define padrões de busca alternativos
- /<string1>/,/<string2>/ – define uma faixa de linhas, delimitadas por 2 strings
- ==, !=, <, >, <=, >= – operadores que podem ser usados na definição de condições de busca
- && (AND) e || (OR) – operadores que conectam duas condições
- +, -, *, /, %, ++, - - – operadores aritméticos
- sqrt, log, exp, int – funções aritméticas
- length, substr, split, index – funções para strings
- while, if, for (sintaxe semelhante à da linguagem C) – estruturas de controle de fluxo

Awk – quer mais exemplos???

Consulte a seção de exemplos do manual do Awk:

`http://www.gnu.org/software/gawk/manual/gawk.html#Sample-Programs`

[Relembrando] O processo de compilação

Um compilador ou interpretador para uma linguagem de programação é geralmente decomposto em duas subtarefas:

1. Ler o código fonte e descobrir sua estrutura
2. Processar essa estrutura, geralmente para gerar um código executável (programa)

A primeira tarefa também pode ser dividida em duas:

1. Dividir o arquivo de entrada em *tokens* (itens léxicos) $\Rightarrow$ **análise léxica**
2. Encontrar a estrutura hierárquica do programa $\Rightarrow$ **análise sintática**

O processo de compilação

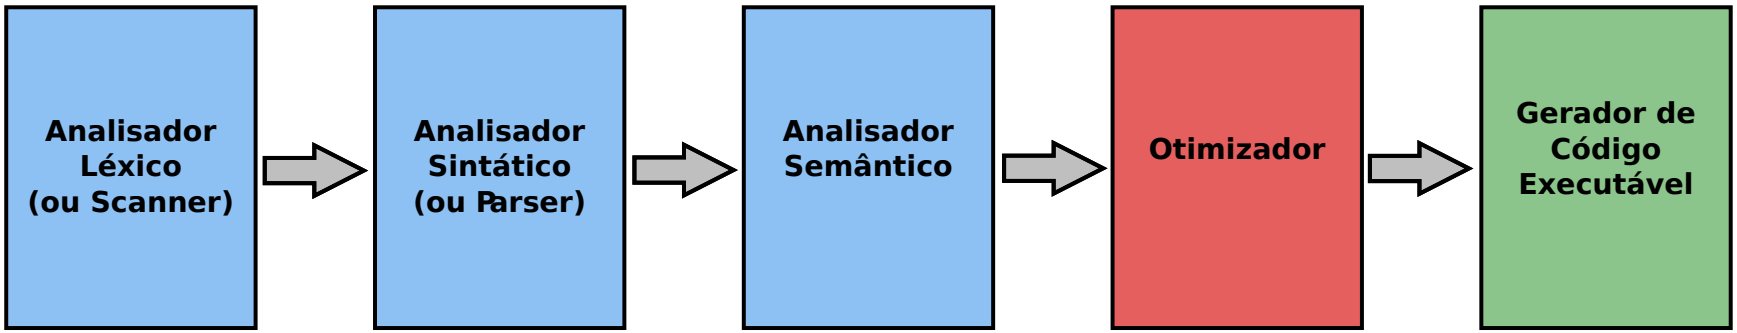

Análise Léxica

`var1 = 1 - 3**2` $\Longrightarrow$

Lexema	Tipo do *token*
var1	Variável
=	Operador de Atribuição
1	Número
-	Operador de Subtração
3	Número
**	Operador de Potência
2	Número

O processo de compilação

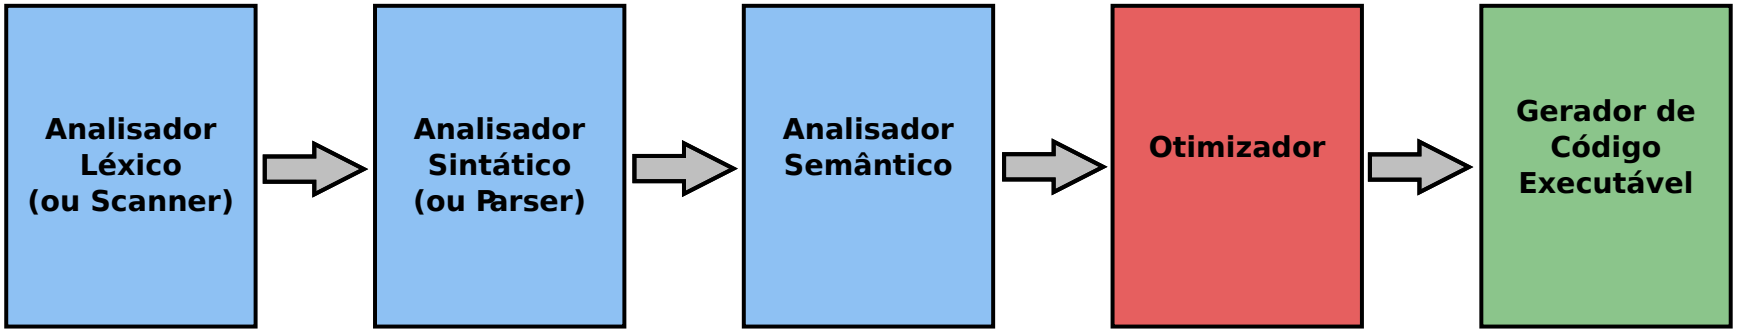

Análise Sintática

Lexema	**Tipo do *token***
var1	Variável
=	Operador de Atribuição
1	Número
-	Operador de Subtração
3	Número
**	Operador de Potência
2	Número

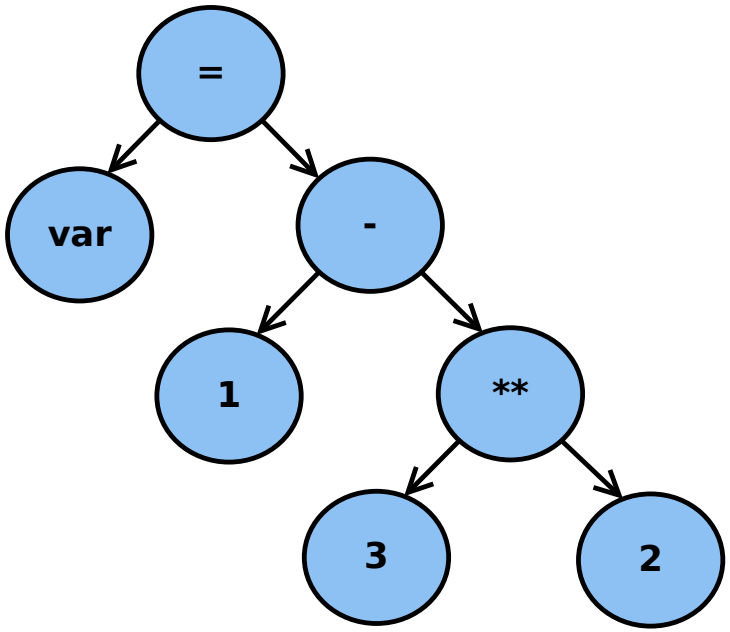

Geradores de Analisadores

- São programas que recebem como entrada um arquivo com uma descrição em alto do que o analisador deve reconhecer e que geram como saída um código que, depois de compilado/interpretado, vira um programa analisador
- Exemplos:
  - **geradores de analisadores léxicos**
    - para C: Lex, Flex
    - para Java: JFlex
  - **geradores de analisadores sintáticos**
    - para C: Yacc, Bison
    - para Java: JavaCC, ANTLR

  Geralmente, são usados em conjunto: Lex + YACC, Flex + Bison

Flex – *Fast Lexical Analyzer Generator*

- Implementação gratuita e de código aberto do Lex
- Distribuído pelo projeto GNU, mas não é parte dele
- **Entrada do programa**: arquivo contendo uma tabela de expressões regulares e suas respectivas ações associações
- **Saída do programa**: o código fonte em C de um analisador léxico que reconhece as expressões regulares especificadas no arquivo de entrada

Formato de um arquivo de entrada para o Flex

O arquivo é dividido em três partes, separadas por linhas que começam com %%:

```
[Definições]
%%
[Regras]
%%
[Código do usuário]
```

Flex – Definições [parte do início]

A seção de *Definições* pode conter:

- **código "literal"** que deve aparecer no analisador fora de qualquer função. Esse código deve ser delimitado por `%{ %}` ou então deve aparecer indentado
- declarações de **definições de nomes simples**. São feitas no formato:

  `[nome] [definição]`

  Exemplos:

```
DIGITO          [0-9]
IDENTIFICADOR   [a-z][a-z0-9]*
```

- declarações de **condições de início** para regras adicionais ou regras exclusivas. São feitas nos seguintes formatos:
  - condição para regras adicionais: `%s [nome]`
  - condição para regras exclusivas: `%x [nome]`

  (Veremos mais detalhes sobre o seu uso mais adiante)

Flex – ...

Continua na próxima aula...

Bibliografia e materiais recomendados

- GNU AWK – Guia do Usuário
  `http://www.gnu.org/software/gawk/manual/gawk.html`
- *An Awk primer* (tutorial de Awk bastante interessante)
  `http://www.vectorsite.net/tsawk.html`
- Manual do Flex
  `http://flex.sourceforge.net/manual/`
- Notas das aulas de MAC0211 de 2010, feitas pelo Prof. Kon
  `http://www.ime.usp.br/~kon/MAC211`

Cenas dos próximos capítulos...

Na próxima aula:

- Flex (continuação)
- Geradores de analisadores sintáticos
- GNU Bison